На правах рукописи



НИКОЛАЕВ Иван Евгеньевич

МЕТОДЫ И АЛГОРИТМЫ ИНТЕЛЛЕКТУАЛЬНОЙ ПОДДЕРЖКИ ФОРМИРОВАНИЯ ТРЕБОВАНИЙ ВАКАНСИИ НА ОСНОВЕ НЕЙРОСЕТЕВЫХ МОДЕЛЕЙ ЯЗЫКА И АКТУАЛЬНЫХ ТРЕБОВАНИЙ РЫНКА ТРУДА

Специальность 2.3.4. Управление в организационных системах

АВТОРЕФЕРАТ
диссертации на соискание ученой степени
кандидата технических наук

Челябинск – 2024

Работа выполнена на кафедре информационных технологий и экономической информатики ФГБОУ ВО «Челябинский государственный университет».

Научный руководитель: доктор технических наук, профессор
Мельников Андрей Витальевич

Официальные оппоненты:
Массель Людмила Васильевна, доктор технических наук, профессор ФГБУН «Институт систем энергетики им. Л.А. Мелентьева» Сибирского отделения Российской академии наук, главный научный сотрудник заведующий отделом «Системы искусственного интеллекта в энергетике»
Малых Валентин Андреевич, кандидат технических наук, ФГАОУ ВО «Национальный исследовательский университет ИТМО», доцент высшей школы цифровой культуры

Ведущая организация: ФГБУН «Институт систем информатики им. А.П. Ершова» Сибирского отделения Российской академии наук

Защита диссертации состоится 29.01.2025 г. в 14:30 часов на заседании диссертационного совета 24.2.479.02, созданного на базе ФГБОУ ВО «Уфимский университет науки и технологий» по адресу: 450008, Республика Башкортостан, г. Уфа, ул. Карла Маркса, д.12.

С диссертацией можно ознакомиться в библиотеке ФГБОУ ВО «Уфимский университет науки и технологий» и на сайте www.uust.ru.

Автореферат разослан «___» _____ 20__ года.

Ученый секретарь

диссертационного совета О.Н. Сметанина

ОБЩАЯ ХАРАКТЕРИСТИКА РАБОТЫ

Актуальность темы исследования.

Современный рынок труда характеризуется высокой динамикой и скоростью изменения требований к компетенциям работников. Формирование точного и полного списка требований к потенциальному работнику является одной из важнейших задач в процессе подбора персонала. Специалисты по подбору персонала сталкиваются со множеством проблем при составлении требований к кандидатам на вакантные должности. Во-первых, рынок труда очень динамичен и требования к соискателям быстро меняются, что затрудняет прогнозирование и определение актуальных требований к кандидатам на фоне быстрого устаревания знаний и навыков. Во-вторых, у самих рекрутеров часто недостает информации и опыта в конкретной сфере для понимания реальных потребностей компании. В-третьих, исследование и анализ требований требуют значительных временных и денежных затрат. В-четвертых, возникают сложности с формулировкой конкретных, объективных и адекватных требований, а также с их согласованием с заинтересованными лицами. Таким образом, процесс определения требований к кандидатам является одним из наиболее проблемных этапов в работе специалистов по подбору персонала.

Чтобы эффективно подбирать персонал, необходим постоянный мониторинг рынка труда и детальный анализ вакансий в разрезе отдельных компетенций. Однако возможности рекрутеров по сбору и обработке больших объемов соответствующих данных ограничены. Одним из решений может стать разработка интеллектуальных рекомендательных систем, которые позволят автоматизировать сбор и анализ информации о востребованных на рынке компетенциях. Такие системы способны выявлять важные закономерности и тенденции, помогать формулировать обоснованные требования к кандидатам с учетом специфики компании и отрасли. Разработка методов интеллектуальной поддержки формирования требований к вакансиям с использованием нейросетевых моделей языка позволит автоматизировать и оптимизировать процесс подбора персонала, сократит издержки на поиск подходящих кандидатов. Создание подобных интеллектуальных систем является актуальной задачей для всей сферы HR (англ. HR – human resources).

Тема исследования тесно связана с приоритетами государственной политики в области развития искусственного интеллекта и цифровых технологий в Российской Федерации. Разработка интеллектуальных методов анализа требований к вакансиям с использованием нейросетевого моделирования соответствует целям национальной стратегии развития искусственного интеллекта на период до 2030 года в части создания конкурентоспособных отечественных решений в сфере ИИ. Результаты исследования могут быть использованы для решения задач цифровизации рынка труда и повышение эффективности подбора персонала. Эти задачи были выделены в рамках национальных инициатив, включая проекты «Цифровая экономика», «Кадры для цифровой экономики» в контексте национальной программы «Цифровая экономика России 2024», а также в контуре Национальной технологической инициативы (НТИ), сфокусированной на обеспечении кадрами для поддержки промышленного развития. Важность этих выводов особенно заметна в аспектах найма и обучения высококвалифицированных специалистов для ключевых и наиболее перспективных секторов рынка труда.

Данное диссертационное исследование посвящено разработке методов и алгоритмов на основе нейросетевых моделей языка и кластерного анализа для автоматизации и повышения эффективности процесса формирования точного и актуального списка требований проекта вакансии, что позволит повысить качество и скорость процессов поиска и подбора кандидатов на вакансии, а также сократить

затраты на подбор персонала. Таким образом, тема является актуальной и имеет большое практическое значение для всех участников рынка труда.

Степень разработанности темы. Методы анализа рынка труда представлены в работах А.П. Цыпина, М.М. Шайлиевой, А.С. Сорокина, И.Б. Хмелева, Е.В. Чекановой, О.П. Толкачевой, А.В. Сапунова, В.В. Гаврилюк, А.А. Ташпулатова, Ю.А. Шварца, А.И. Смирновой, А.В. Пахомова, Е.А. Пахомовой, О.В. Рожковой, И.А. Волошиной, Л.В. Козловой, П.Н. Новикова, П.А. Лебедева, Д.А. Шурыгиной, А.Д. Волгина, В.Е. Гимпельсона, И.Н. Калиновской, О.А. Хохловой, А.Н. Хохловой, А.Ц. Чойжалсановой, Е.Н. Бавыкиной, С.С. Гущиной, Т.В. Корецкой, В.С. Половинко, Р.А. Долженко, С.Б. Долженко, А.О. Епанчинцева, Д.С. Ботова, R. Boselli, F. Mercorio, M. Mezzanzanica, A. Giabell, E. Colombo, I. Konstantinidis, M. Zhang, K.N. Jensen и других исследователей.

В существующих методах анализа рынка труда предложено множество подходов, но эти решения имеют ряд ограничений. Большинство исследований рынка труда связаны со статистическим анализом макростатистики и макропоказателей, и направлены на комплексный анализ спроса и предложения рабочей силы для обеспечения эффективного функционирования рынка труда. Данные исследования не позволяют проанализировать спрос и предложение на уровне отдельных сущностей требований, таких как знания и навыки/компетенции. В тех исследованиях, которые пытаются анализировать рынок труда на уровне анализа текстов вакансий, как правило, используются модели дистрибутивной семантики прошлого поколения, такие как TF-IDF, word2vec.

В последнее время наиболее востребованным направлением для анализа текстовой информации являются нейросетевые модели на архитектуре трансформеров с механизмом внимания. Отличительной особенностью таких моделей является контекстуальное понимание всех слов в тексте, что позволяет лучше распознавать долгосрочные зависимости между словами. В настоящее время такие модели достигли лучших оценок на большинстве задач обработки и понимания естественного языка, чем модели предыдущих поколений.

Данное диссертационное исследование посвящено решению актуальной задачи интеллектуальной поддержки процесса формирования точного и актуального списка требований на уровне отдельных сущностей знаний и навыков/компетенций при составлении списка требований для вакансии. Проведенный анализ существующих публикаций и практических исследований показал, что предложенный набор методов и алгоритмов, основанных на интеллектуальном анализе текстов вакансий, ранее не упоминался и не использовалась в контексте задачи интеллектуальной поддержки составления списка требований для вакансий. Таким образом, тема данной диссертационной работы, связанная с разработкой методов и алгоритмов для автоматизации анализа реальных (фактических) данных о требованиях рынка труда на уровне отдельных сущностей требований, является актуальной.

Цель и задачи диссертационной работы. Целью работы является разработка методов и алгоритмов интеллектуальной поддержки процесса формирования требований к вакансиям, которые обеспечат повышение качества анализа современных тенденций рынка труда, повысят эффективность процессов подбора персонала и соответствие разрабатываемых требований в проектах вакансий реальным потребностям рынка труда.

Для достижения указанной цели необходимо было решить следующие задачи:

1. Разработать модель формализованного описания требований реального рынка труда на уровне отдельных сущностей знаний и навыков/компетенций, учитывающую структурные и семантические отношения между ними.

2. Разработать метод и алгоритм извлечения сущностей знаний и навыков/компетенций из текстов требований вакансий реального рынка труда на основе нейросетевых моделей языка и методов классификации.

3. Разработать интеллектуальный метод поддержки формирования списка требований вакансий на основе семантического сопоставления сущностей знаний и навыков/компетенций предложенной структурно-семантической модели и применения методов кластеризации.

4. Выполнить программную реализацию предложенных методов, моделей и алгоритмов в виде прототипа интеллектуальной рекомендательной системы информационной поддержки формирования требований вакансии.

5. Провести оценку эффективности реализованных методов и алгоритмов интеллектуальной поддержки формирования требований на текстовом корпусе проектов вакансий.

Объектом исследования является процесс формирования требований в проекте вакансий, включая формулирование и корректировку разрабатываемых требований в соответствии с потребностями реального рынка труда.

Предметом исследования являются методы и алгоритмы интеллектуальной поддержки формирования требований в проектах вакансий.

Научная новизна диссертационной работы заключается в следующем:

– Предложена модель формализованного описания требований рынка труда на уровне отдельных сущностей знаний и навыков/компетенций в виде структурно-семантической модели, которая позволяет учитывать структурные и семантические отношения между сущностями. Такое формализованное представление сущностей требований рынка труда может быть сформировано автоматически, в отличие от существующих работ, требующих ручных методов разработки онтологических моделей предметной области (п. 2 п.с.).

– Разработан метод извлечения сущностей знаний и навыков/компетенций из текстов требований вакансий реального рынка труда, на основе нейросетевых моделей языка и методов классификации, который в отличие от существующих методов не требует, чтобы искомые сущности были представлены в виде последовательности подряд идущих синтаксических или лексических конструкций, и позволяет извлекать существенно больше информации об отдельных сущностях требований из текстов вакансий реального рынка труда (п. 5 п.с.).

– Разработан интеллектуальный метод поддержки формирования требований вакансии на основе семантического сопоставления сущностей знаний и навыков/компетенций предложенной структурно-семантической модели и методов кластеризации, который обеспечивает соответствие разрабатываемых требований в проектах вакансий реальным потребностям рынка труда (п. 9 п.с.).

Теоретическая и практическая значимость работы. Предложенные в работе модели, методы и алгоритмы дают научное обоснование механизмов для интеллектуальной поддержки формирования актуального и точного списка требований в процессе составления текста вакансии и сочетают формальные модели представления отдельных сущностей требований и отношений между ними с методами семантического анализа текстов на основе нейросетевых моделей языка и кластерного анализа.

Созданный на основе предложенных моделей, методов и алгоритмов прототип интеллектуальной системы поддержки формирования актуального списка требований в процессе составления текста вакансии может быть применен в службах занятости и отделах кадров для формирования более полного и точного списка требований к соискателям. Это позволит решить проблему разрыва между содержанием текста вакансии и требованиями реального рынка труда, а также позволит сократить время и

ресурсы на анализ и подготовку итогового списка требований при подготовке текста вакансии.

Методология и методы исследования. Диссертационное исследование базируется на различных методах, включая системный анализ, системное моделирование, теорию принятия решений, искусственный интеллект, инженерию знаний, методы машинного обучения, анализ данных, обработку естественного языка, теорию множеств и графов, разработку интеллектуальных систем, а также объектно-ориентированное проектирование и разработку информационных систем. Эти методы являются теоретической и методологической основой исследования.

Положения, выносимые на защиту:

1. Структурно-семантическая модель описания требований реального рынка труда на уровне отдельных сущностей знаний и навыков/компетенций, включающая формализованное описание сущностей в виде графа с учетом структурных и семантических отношения между сущностями.
2. Метод извлечения сущностей знаний и навыков/компетенций из текстов требований вакансий реального рынка труда, на основе нейросетевых моделей языка и методов классификации.
3. Интеллектуальный метод поддержки формирования требований вакансии на основе семантического сопоставления сущностей знаний и навыков/компетенций предложенной структурно-семантической модели и методов кластеризации.
4. Оценка эффективности реализованных методов и алгоритмов интеллектуальной поддержки формирования требований на текстовом корпусе проектов вакансий.

Обоснованность и достоверность результатов. Полученные в диссертационном исследовании результаты обоснованы применением проверенных математических методов: теории графов, теории множеств, векторной алгебры, а также статистической обработки данных. Использованы известные теоретические положения в области анализа естественного языка и интеллектуальной поддержки принятия решений.

Адекватность предложенных методов и алгоритмов подтверждена экспериментально на значимых текстовых данных, а также внедрением и апробацией прототипа интеллектуальной рекомендательной системы на реальных предприятиях. Достоверность экспериментальных результатов обеспечена применением устоявшихся подходов к оценке качества информационного поиска, классификации и кластеризации текстов. Также проводилась корректная статистическая обработка данных и анализ высокой согласованности мнений экспертов.

Апробация результатов. Основные положения и результаты работы докладывались и обсуждались на следующих научных конференциях:

– 7-я всероссийская научная конференция с международным участием «Информационные технологии и системы» (ИТиС’2019) (12 – 16 марта 2019 г., Ханты-Мансийск);

– 9-я всероссийская научная конференция с международным участием «Информационные технологии интеллектуальной поддержки принятия решений» (ITIDS’2021) (7 – 9 декабря 2021 г., Уфа);

– Семинар «Методы искусственного интеллекта в решении прикладных задач» (23 – 27 августа 2023 г., Ханты-Мансийск).

Результаты диссертационной работы внедрены в следующих организациях: Челябинский государственный университет (г. Челябинск), Югорский научно-исследовательский институт (г. Ханты-Мансийск), компания ООО Фирма «Интерсвязь»

(г. Челябинск), что подтверждается приведенными в приложении актами о внедрении научных положений и разработок диссертации в практику деятельности организации.

Публикации. По результатам диссертационного исследования опубликовано 9 печатных работ, в том числе 3 работы в рецензируемых печатных изданиях, рекомендованных ВАК, 5 работ в изданиях, индексируемых в Scopus и Web of Science, и 1 публикация в других научных журналах и сборниках трудов конференций. Получено 1 свидетельство о государственной регистрации программы для ЭВМ.

Личный вклад автора. Модели и методы интеллектуальной поддержки принятия решений, метод извлечения отдельных сущностей знаний и навыков/компетенций, структура прототипа интеллектуальной системы были предложены, описаны и разработаны автором лично. Персональный вклад автора подробно отражают основные положения, выносимые на защиту, и публикации по теме диссертации.

Структура и объем диссертации. Диссертационная работа состоит из введения, четырех глав, заключения и списка литературы. Объем работы составляет 162 страница основного текста, включая 31 рисунка, 17 таблиц, 4 приложения. Список литературы содержит 118 наименование.

ОСНОВНОЕ СОДЕРЖАНИЕ РАБОТЫ

Во **введении** обосновывается актуальность темы диссертационного исследования, сформулированы цель и задачи работы, определяется объект и предмет исследования, отмечается научная новизна и практическая значимость полученных результатов, а также приводятся данные о структуре и объеме диссертации.

В **первой главе** проводится анализ основных понятий, процедур и проблем, связанных с процессом подбора персонала.

Проводится анализ исследований российских и зарубежных ученых по разработке методов, моделей и алгоритмов интеллектуального анализа рынка труда. Анализ показал, что существующие на сегодняшний день интеллектуальные методы анализа требований рынка труда основываются либо на анализе статистической информации, которые по определению не позволяют оценить изменения в каждой профессии или отрасли на уровне отдельных требований; либо предлагают малоэффективные подходы анализа текстовой информации на основе векторных представлений прошлого поколения, такие как, TF-IDF, word2vec.

Проанализированы современные модели векторного представления текстов в задаче определения семантической близости текстов. С целью преодоления проблемы большого количества попарных сравнений векторных представлений текстов проанализированы существующие модели построения векторных индексов.

Проанализированы современные методы извлечения именованных сущностей. Проанализированы основные виды проблемы в процессе извлечения именованных сущностей.

Проводится анализ существующих систем онлайн рекрутмента. В результате анализа текстов вакансий были выявлены проблемы, связанные с отсутствие жесткой структуры в текстах вакансий. Также в результате анализа текстов требований из вакансий было выявлено, что большинство из них представляют собой сложно организованные тексты, что делает использование существующих методов извлечения именованных сущностей малоэффективными в задаче извлечения текстов отдельных сущностей требований, таких как знания и навыков/компетенции из текстов вакансий для дальнейшего анализа.

Во **второй главе** описывается концепция информационной поддержки формирования требований вакансии на основе семантического сопоставления сущностей требований структурно-семантической модели и методов кластеризации. Описывается методика решения, используемые методы, схема управления и основные блоки схемы управления процессом формирования рекомендаций, реализующей концепцию, алгоритмы работы с системой и ограничения использования системы.

Описывается ключевой компонент концепции – структурно-семантическая модель требований реального рынка труда на уровне отдельных сущностей знаний и навыков/компетенций, включающая формализованное описание сущностей в виде графа $G_{LM} = (V_{LM}, E_{LM})$ с учетом структурных и семантических отношений между сущностями. Где V_{LM} – множество вершин графа, описывающих сущности отдельных требований рынка труда двух типов: знания и навыки/компетенции, а E_{LM} – множество ребер графа, описывающих связи между сущностями требований на графе.

Каждая вершина графа $v \in V_{LM}$ определяется кортежем атрибутов (1):

$$v =< text, pop(v), type(v), emb(v), hyperonim(v) >, \quad (1)$$

где:

– $text$ – текст сущности.

– $pop(v)$ – обозначает частотность узла v. Частотность представляет собой числовое значение, отражающее встречаемости данной сущности в текстах вакансий, представленных на рынке труда.

– $type(v)$ – обозначает тип узла v. Тип представляет категорию или класс, к которому относится данная сущность знаний или навыков/компетенций.

– $emb(v)$ – обозначает векторное представление (эмбеддинг) узла v, полученный с помощью нейросетевой модели.

– $hyperonim(v)$ – гипероним (общее понятие) для сущности.

Каждое ребро графа $e \in E_{LM}$ определяется следующим кортежем атрибутов (2):

$$e =< v_s, v_t, w(v_s, v_t) >, \quad (2)$$

где:

– v_s, v_t – обозначают концевые сущности, соединенные ребром e. Концевые сущности являются узлами графа.

– $w(v_s, v_t)$ – обозначает вес ребра e. Вес представляет собой числовое значение, которое отражает частоту совместной встречаемости двух связанных сущностей в текстах требований из вакансий.

Схема структурно-семантической модели отдельных сущностей требований рынка представлена на рисунке 1. Фрагмент структурно-семантической модели на реальных требованиях рынка труда представлен на рисунке 2.

Также описывается алгоритм *поиска гиперонима синонимов сущностей* (ПГСС).

Пусть $emb(v_i)$ – векторное представление текста i-ой сущности.

Пусть $pop(v_i)$ – показатель частотности i-ой сущности.

Пусть E – порог косинусной меры близости для отбора ближайших соседей.

Алгоритм объединения синонимов сущностей:

Шаг 1. По формуле 3 для каждой сущности v_i формируем множество ее ближайших соседей S_i из сущностей v_j в некоторой окрестности E по косинусной мерt близости:

$$S_i = \left\{ j \middle| \cos\left(emb(v_i), emb(v_j)\right) < E \right\}. \quad (3)$$

Шаг 2. Среди множества отобранных вершин S_i определяем вершину-гипероним с наибольшей частотой упоминания чем у исходной вершины v_i (4).

$$hyperonim(v_i) = \begin{cases} S_i = \emptyset \mid null \\ S_i \neq \emptyset \mid v_k, k = \underset{j \in S_i}{arg\,max}\, pop(v_j) \end{cases}. \quad (4)$$

Если среди отобранных вершин S_i, есть вершина v_k с большей частотой встречаемости чем у исходной вершины v_i, тогда вершина v_k становится гиперонимом для исходной вершины v_i, если среди S_i нет вершины v_k с большей частотой встречаемости, чем у исходной вершины v_i, тогда v_i считается конечной вершиной, и может считаться гиперонимом в данной окрестности E.

Фактически, на данном этапе для каждой вершины на основе векторно-частотного анализа по очень небольшой окрестности определяется наиболее популярный синоним, который в некоторой степени можно считать гиперонимом для рассматриваемой сущности. Пример работы алгоритма ПГСС представлен на рисунке 2.

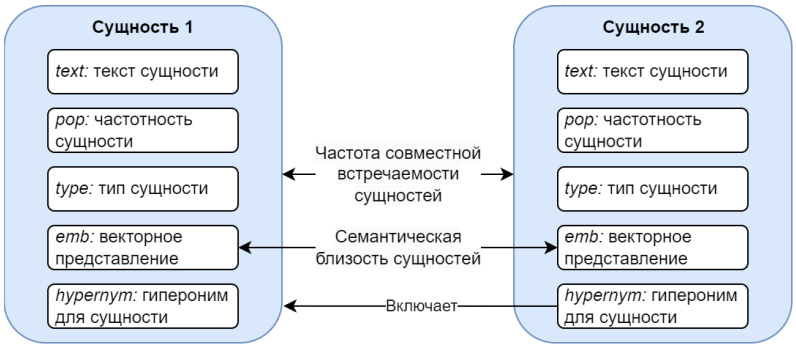


Рисунок 1 – Схема структурно-семантической модели отдельных сущностей требований рынка

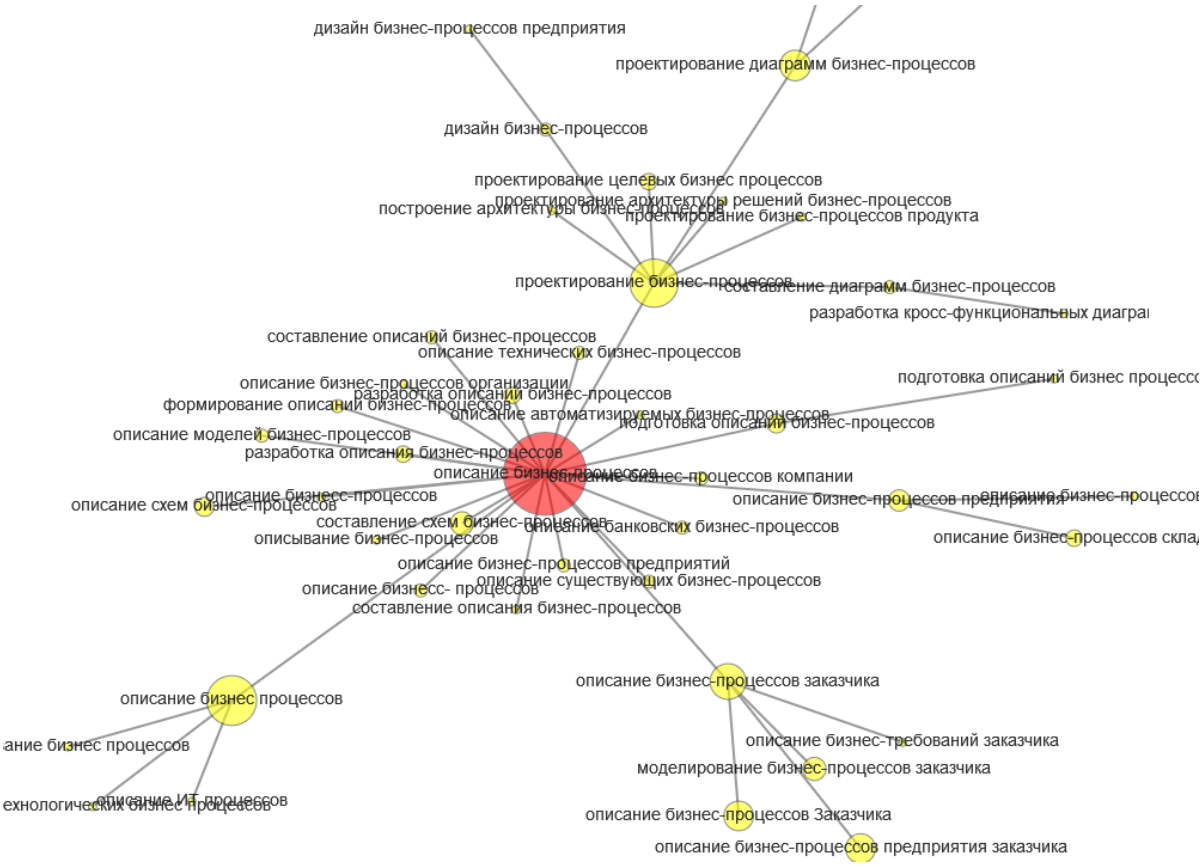


Рисунок 2 – Пример работы алгоритма ПГСС на фрагменте структурно-семантической модели.

Также во второй главе описывается метод извлечения отдельных сущностей требований из текстов вакансий, основанный на нейросетевых моделях языка и методах классификации. Общая схема метода представлена на рисунке 3.

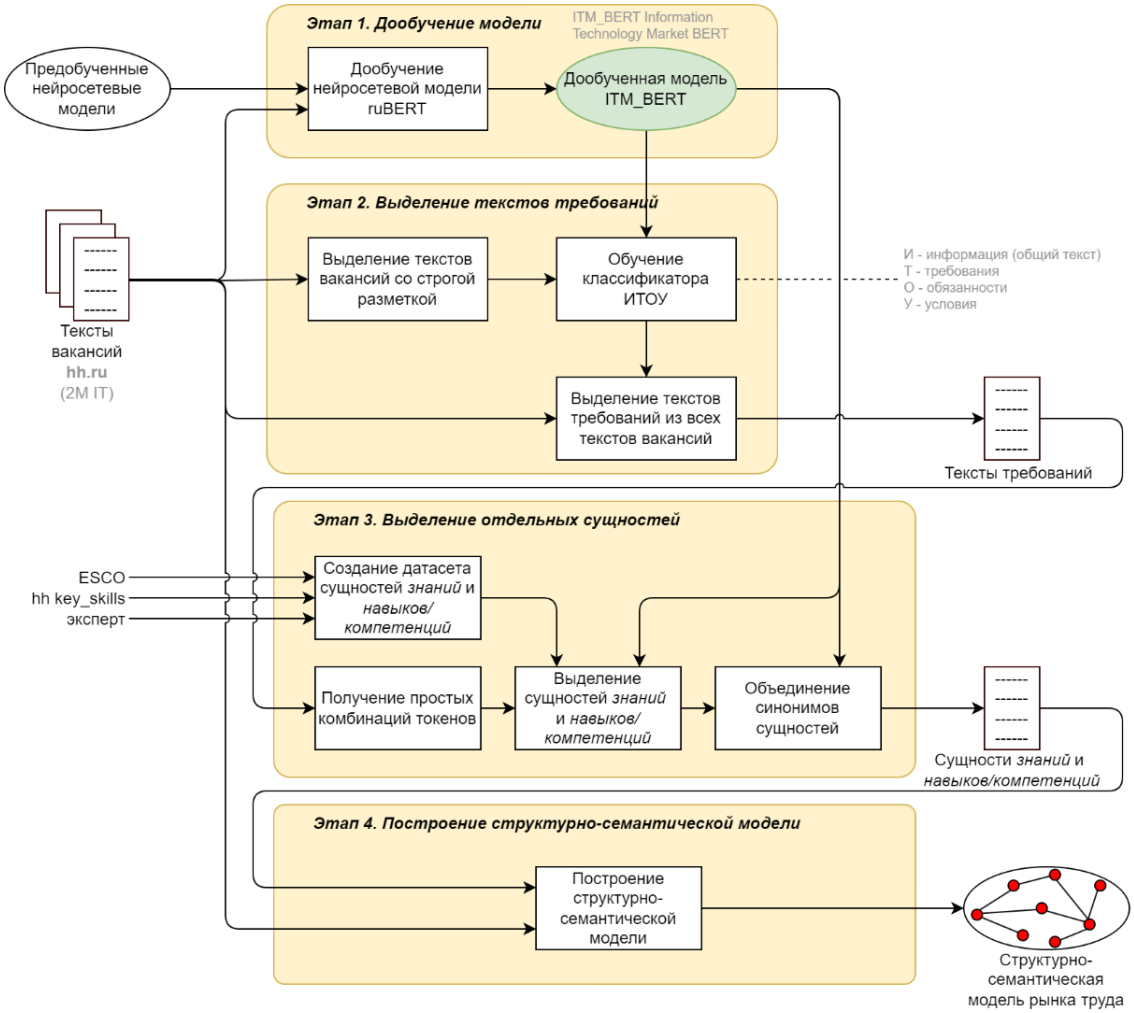


Рисунок 3 – Метод извлечения отдельных сущностей требований из текстов вакансий

В **третьей главе** описывается интеллектуальный метод поддержки формирования списка требований вакансии на основе семантического и частотного сопоставления сущностей знаний и навыков/компетенций предложенной структурно-семантической модели и кластерного анализа (метод включает в себя 3 этапа). Схема метода представлена на рисунке 4. В предлагаемом методе можно выделить три основных этапа.

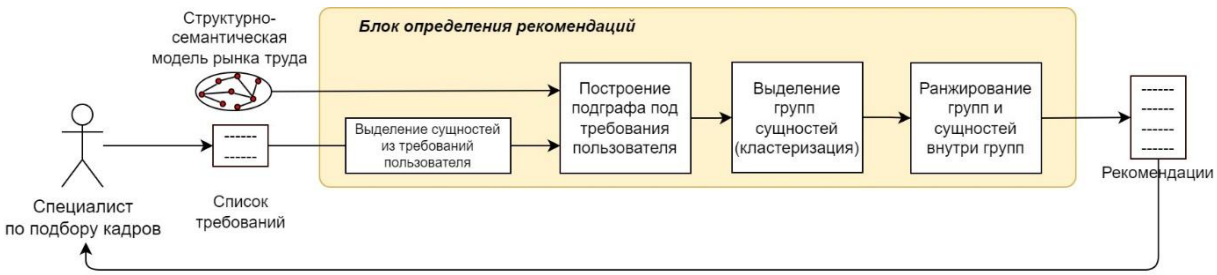


Рисунок 4 – Схема интеллектуального метода формирования рекомендуемых групп требований

Этап 1. Построение подграфа сущностей структурно-семантической модели с учетом требований пользователя. Суть этого этапа заключается в том, чтобы отобрать группы сущностей требований знаний и навыков/компетенций смежных с теми, которые пользователь указал в исходном списке требований, который он собирается расширять новыми сущностями. Фактически, на этом этапе строится подграф исходной структурно-семантической модели отдельных сущностей требований только из тех сущностей требований, которые имеют общую связь в исходном графе, т.е. хотя бы раз совместно встречались в текстах вакансий.

Пусть $G_{LM} = (V_{LM}, E_{LM})$ – структурно-семантическая модель, описанная выше. Пусть U – список сущностей *знаний* и *навыков/компетенций*, которые вводит пользователь. Каждый элемент $u \in U$ и $v \in V_{LM}$ имеет свое собственное векторное представление $emb(u)$ и $emb(v)$, соответственно. Пусть $sim(u, v)$ обозначает семантическую меру близости между векторными представлениями узлов u и v. В данном случае, в силу большого количества сущностей и попарных сравнений между ними, мы используем не классическую косинусную меру близости, а эквивалент в виде иерархического индекса (от англ. HNSW – Hierarchical Navigable Small Worlds) определенного с помощью библиотеки faiss.

Инициализация. Создаем пустое множество S для синонимов сущностей для каждого $u \in U$. Создаем пустое множество V' для списка соседних с $s \in S$ сущностей. Создаем пустое множество E' для ребер между узлами S и V'.

Отбор синонимов сущностей требований, заданных пользователем. Для каждого $u \in U$ находим узел $v \in V$ с наибольшей семантической мерой близости к u, такой что:

$$v = argmax_{v \in V} sim\big(emb(u), emb(v)\big). \quad (3)$$

Добавляем узел v в S.

Отбор соседних сущностей требований. Для каждого узла $s \in S$ добавляем все узлы $v \in V$, такие что (s, v) является ребром графа G_{LM}, в V'. Добавляем ребро (s, v) в множество ребер E'. В результате у нас получается подграф исходного графа $G' = (V', E')$ под исходные требования пользователя.

Этап 2. Выделение групп сущностей на основе кластерного анализа. Суть этого этапа заключается в том, чтобы отобранные на этапе 1 сущности разбить на семантические группы (кластеры). Для вычисления оптимального количества кластеров используется комплексная оценка на основе двух метрик оценки качества кластеризации оценка силуэта и индекс Девиса Болдина.

Инициализация. Пусть EMB – это множество векторных представлений сущностей из полученного подграфа, которые мы хотим разбить на семантические кластеры; k – параметр, представляющий количество кластеров, которое мы рассматриваем от 2 до k_{max},. k_{max} – гиперпараметр, который задается пользователем; $C = \{C_1, C_2, \dots, C_k\}$ – множество кластеров, где каждый кластер C_i содержит подмножество, где $v \in V'$; $SIL = \{sil_2, sil_3, \dots, sil_{k_{max}}\}$ – множество значений оценок силуэта для каждого значения параметра k; $DBI = \{dbi_2, dbi_3, \dots, db_{k_{max}}\}$ – множество значений индекса Девиса-Болдина для каждого значения параметра k.

Алгоритм выделения групп сущностей требований.

Для каждого значения k от 2 до k_{max} :

- Кластеризуем множество EMB методом K-Means на k кластеров.
- Вычисляем оценку силуэта sil_k для полученных кластеров C и сохраняем в SIL.
- Вычисляем индекс Девиса-Болдина dbi_k для полученных кластеров C и сохраняем в DBI.

Вычисляем покомпонентную разность между списками SIL и DBI (4):

$$diff = |SIL - DBI|. \quad (4)$$

Выбираем значение k, которое соответствует наибольшей разности $diff$ (5).

$$k = argmax(diff). \quad (5)$$

Алгоритм позволяет найти наилучшее количество кластеров, на основе совокупной оценки силуэта и индекса Девиса-Болдина.

Этап 3. Ранжирование групп и сущностей внутри групп на основе частотной информации о сущностях. Суть этого этапа заключается в том, чтобы сформировать ответ системы в виде ранжированного списка групп требований, в котором группы, которые имеют более явную совокупную семантическую связь с исходным списком требований отображались в верхней части, а группы, которые имеют менее выраженную семантическую связь – в нижней части. Списки сущностей требований внутри кластеров (групп) тоже ранжируются, но уже по частоте упоминания в текстах вакансий (по популярности).

Для каждого кластера $C_i \in C$ вычисляем сумму совместной встречаемости по всем узлам в кластере с узлами из множества синонимов S (6):

$$score_i = \sum_{(u,v)\in E', u\in V', v\in C_i} w(u,v)\,. \quad (6)$$

Сортируем кластеры в C по убыванию суммы совместной встречаемости $score_i$.

$$C' = \left(C_{i_1}, C_{i_2}, \dots, C_{i_k}\right), score_{i_1} \geq score_{i_2} \geq \cdots \geq score_{i_k}. \quad (7)$$

Ранжирование сущностей внутри групп происходит по параметру частотности:

$$C_i{}' = \left(v_{i_1}, v_{i_2}, \dots, v_{i_m}\right), p(v_{i_1}) \geq p(v_{i_2}) \geq \cdots p(v_{i_m})\,. \quad (8)$$

Метод позволяет найти семантически ближайшие группы требований к заданным требованиям пользователя, а также ранжирует их в зависимости от степени совместной встречаемости в вакансиях реального рынка труда.

Общая схема формирования рекомендаций по предложенному методу представлена на рисунке 5. Можно увидеть, что при добавлении нового требования 3 в исходный список требований, кластеры, их ранжирование и ранжирование внутри кластеров перестраиваются в соответствии с описанным выше методом.

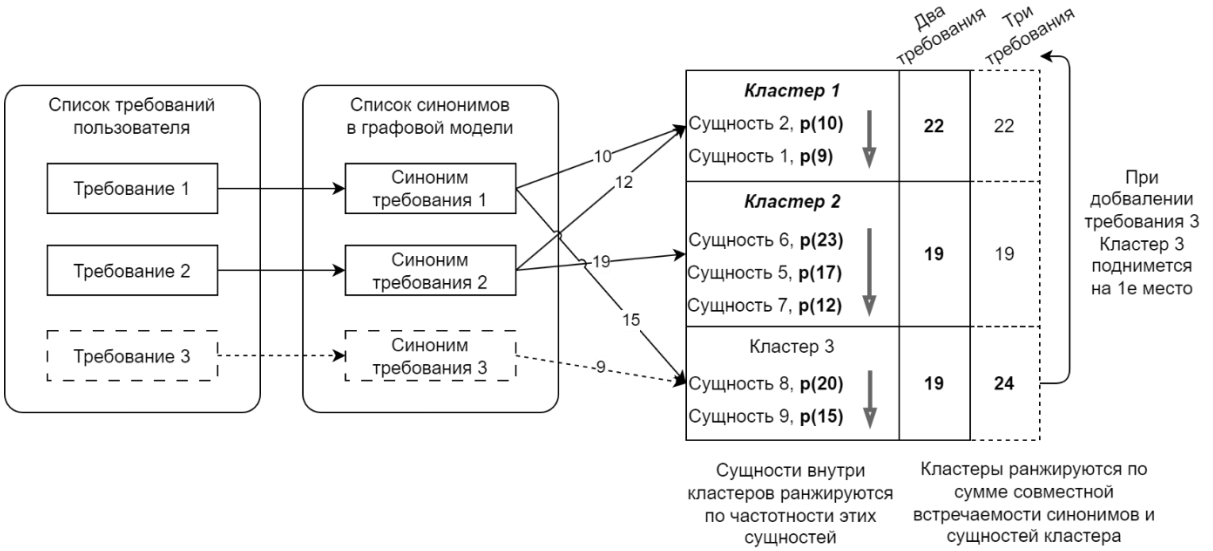


Рисунок 5 – Схема изменения групп рекомендуемых навыков при добавлении нового требования в список требований пользователя

ОПИСАНИЕ ЭКСПЕРИМЕНТОВ

Для построения структурно-семантической модели и дообучения нейросетевых моделей BERT были собраны датасет вакансий (см. таблицу 1) и датасет размеченных знаний и навыков/компетенций (см. таблицу 2), а также реализованы методы извлечения текстов требований из текстов вакансий и извлечения отдельных сущностей знаний и навыков/компетенций из текстов требований.

Таблица 1 – Содержание текстовых корпусов для экспериментов

Корпус (только ИТ вакансии)	Число текстов it-вакансий	Число текстов it-вакансий со строгой html-разметкой	Число извлеченных требований
Корпус вакансий headhunter.ru	1.8 млн.	~423 тыс.	4.9 млн
Корпус вакансий superjob.ru	0.3 млн.		1.5 млн.
Итого	2.1 млн.	423 тыс.	6.4 млн.

Таблица 2 – Структура корпуса текстов знаний и навыков/компетенций из отрасли ИТ

Ресурс	Количество уникальных текстов	Количество текстов знаний	Количество текстов навыков/компетенций
ESCO	9936	2411	7525
hh.ru	50135	20342*	29793*
znantrend.ru	19123	6342*	12781*
Итого	79194	29095	50099

*дополнительно размечались экспертом

Дообучение на специфических текстах предметной области предобученных нейросетевых языковых моделей на архитектуре трансформеров существенно повышает качество использования этой модели в задачах NLP при работе с текстами этой предметной области.

Для дообучения языковых моделей был сформирован датасет из 500 тыс. случайно отобранных текстов вакансий из основного датасета вакансий (см. таблицу 2).

В качестве основных моделей были взяты две предобученные модели для русского языка от проектной группы ai-forever (ранее Sberbank-AI): sberbank-ai/ruBert-base (178M параметров) и sberbank-ai/ruBert-large (427M параметров).

Основной метод дообучения MLM (Masked-Language Modeling), маскировалось 15% слов (токенов). Оценка качества дообучения языковых моделей производилась по метрике перплексия.

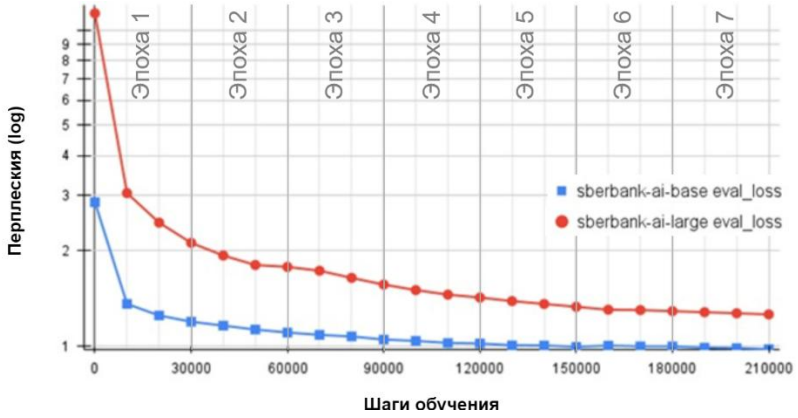


Рисунок 6 – Оценка качества дообучения языковых моделей по метрике перплексия

Результаты эксперимента извлечения текстов требований из текстов вакансий на основе классификации предложений в текстах вакансий (представлены в таблице 3). Были проанализированы результаты нескольких вариантов классификации: на основе дообучения последних слоев двух языковых моделей sberbank-ai/ruBert-base и sberbank-ai/ruBert-base-finetuned.

Таблица 3 – Результаты выделения текстов требований из текстов вакансий

Наименование	Класс Общий текст	Класс Требования	Класс Обязанности	Класс Условия
sberbank-ai/ruBert-base + classification_layer	0.72	0.70	0.71	0.73
sberbank-ai/ruBert-base-finetuned + classification_layer	0.83	0.89	0.89	0.87

Затем из всех текстов вакансий были извлечены только тексты требований (см. таблицу 1, столбец «число извлеченных требований»).

Результаты извлечения отдельных сущностей знаний и навыков/компетенций из текстов требований, представлены в таблице 4. В эксперименте проводилось сравнение двух подходов для формирования простых комбинаций токенов: на основе линейной комбинации слов и путем расширения дерева синтаксического разбора сложного предложения новыми связями. На финальном этапе по метрики F1 сравнивалось количество извлеченных сущностей знаний и навыков/компетенций по предложенному методу с экспертной разметкой.

Таблица 4 – Результаты сравнения различных комбинаций инструментов в работы метода извлечения знаний и навыков/компетенций

Модель	Токенизатор и синтаксический парсер	Схема получения комбинаций токенов	F1
yargy-парсер (baseline)			0.31
ruBert-base	spacy_base	линейная комбинация	0.65
ruBert-base	spacy_base	дополнение дерева	0.33
ruBert-base	deeppavlov_syntax_parser	линейная комбинация	0.58
ruBert-base	deeppavlov_syntax_parser	дополнение дерева	0.35
ruBert-base-finetuned	spacy_base	линейная комбинация	0.81
ruBert-base-finetuned	spacy_base	дополнение дерева	0.69
ruBert-base-finetuned	deeppavlov_syntax_parser	линейная комбинация	0.83
ruBert-base-finetuned	deeppavlov_syntax_parser	дополнение дерева	0.71

В эксперименте по оценке точности семантического поиска рекомендуемых групп требований под список исходных требований, заданный специалистом по подбору кадров, 9 экспертами были даны оценки релевантности на 133 запросах. Для оценки точности использовалась метрика информационного поиска Mean average precision (MAP).

По результатам оценки точности (см.таблица 5) можно отметить, что после 5 ближайших значений в группе, релевантность элементов в выдаче рекомендаций начинает снижаться. Также можно наблюдать, что дообученная модель демонстрирует более высокую релевантность выдачи и превосходит модель без дообучения.

Таблица 5 – Результаты эксперимента по оценке точности семантического поиска под исходный список требований пользователя.

Векторное представление	MAP@1	MAP@3	MAP@5	MAP@10
sberbank-ai/ruBert-base	0,725	0,673	0,625	0,504
sberbank-ai/ruBert-base-finetuned	0,855	0,822	0,793	0,654

Четвертая глава посвящена разработке прототипа интеллектуальной рекомендательной системы поддержки формирования списка требований для проектов вакансии на основе предложенных моделей, методов и алгоритмов. Структура интеллектуальной рекомендательной системы поддержки формирования списка требований вакансии по актуальным требования рынка труда приведена на рисунке 7.

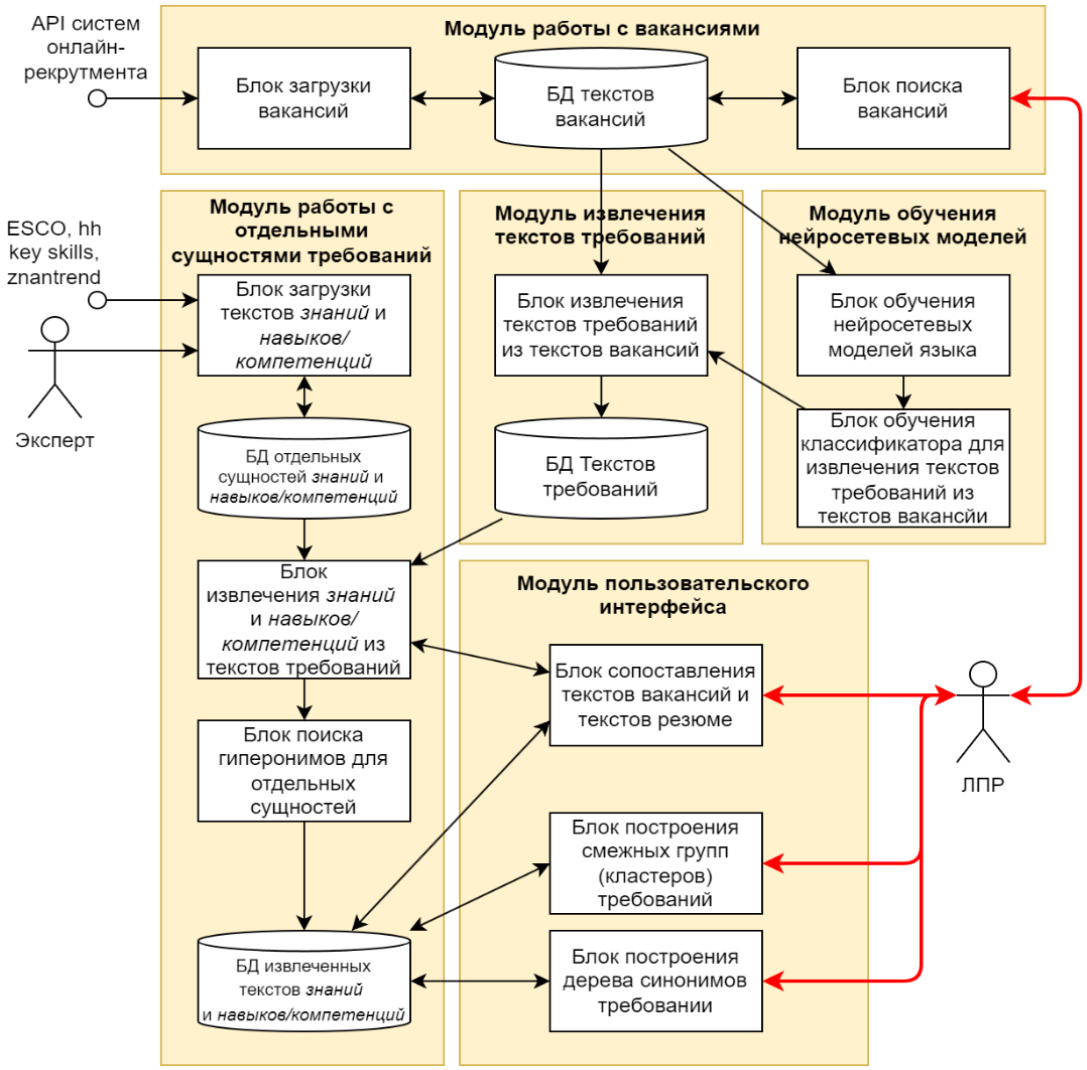


Рисунок 7 – Структура прототипа интеллектуальной рекомендательной системы поддержки формирования списка требований вакансии по актуальным требованиям рынка труда

Программная реализация рекомендательной системы выполнена на языке Python 3.9 с использованием веб-фреймворка Flask, в качестве СУБД использовалась MySQL. Для обучения нейросетевых моделей BERT и классификаторов на основе нейронных сетей использовалась библиотека HuggingFace, для остальных алгоритмов классификации и кластеризации, а также для оценки качества проводимых

экспериментов использовалась библиотека scikit-learn. Для извлечения сущностей из текстов вакансий использовалась открытая библиотека Yargy. Для построения графов использовалась библиотека NetworkX, а для их отрисовки и визуализации библиотека plotly.

Оценка эффективности применения рекомендательной системы

Эффективность управленческих решений, принятых с использованием прототипа интеллектуальной системы, заключается в повышении степени соответствия формируемых требований проекта вакансии с реальными требованиями рынка труда и тем самым повышается эффективность процесса кадрового обеспечения. Результаты представлены в таблице 6.

– Сокращение среднего времени подготовки вакансии за счет сокращения времени на анализ требований по аналогичным позициям.

– Увеличение среднего количества подходящих кандидатов за счет более точного описания требуемых навыков и квалификации.

– Уменьшение среднего времени закрытия одной вакансии

Таблица 6 – Результаты оценки эффективности применения рекомендательной системы

Метрика	Было	Стало	Процент изменения
Среднее время подготовки вакансии (часов)	4	1,5	↓62,5%
Количество соискателей в среднем на одну вакансию	3,7	4,3	↑16,2%
Время закрытия одной вакансии (дней)	17,7	15,1	↓14,7%

Отдельно можно отметить потенциальные возможности применения интеллектуальной рекомендательной системы экспертами для актуализации содержания профессиональных стандартов, образовательных программ и государственных классификаторов занятия под требования реального рынка труда.

ОСНОВНЫЕ ВЫВОДЫ И РЕЗУЛЬТАТЫ РАБОТЫ

В диссертационной работе достигнута цель исследования – разработаны методы и алгоритмы интеллектуальной поддержки формирования списка требований к вакансиям, которые обеспечивают повышение качества анализа современных тенденций рынка труда, повышают эффективность процесса подбора персонала и соответствие разрабатываемых требований в проектах вакансий реальным потребностям рынка труда.

При выполнении задач исследования были получены следующие результаты:

1. На основе результатов анализа предметной области с учетом выявленных проблем и ограничений существующих методов предложена структурно-семантическая модель формализованного описания требований рынка труда на уровне отдельных сущностей знаний и навыков/компетенций. Данная модель позволяет учитывать структурные и семантические связи между отдельными сущностями требований, и может быть сформирована автоматически.

2. На основе нейросетевых моделей языка и методов классификации разработан метод извлечения отдельных сущностей знаний и навыков/компетенций из текстов требований вакансий реального рынка труда, который в отличии от существующих методов не требует, чтобы искомые сущности были представлены в виде последовательности подряд идущих синтаксических или лексических конструкций. По результатам экспериментов предложенный метод демонстрирует существенный

прирост качества извлечения отдельных сущностей знаний и навыков/компетенций из текстов требований вакансий по метрике F1 по сравнению с существующими методами, основанными на правилах, 0.81 против 0.31, соответственно.

3. Разработан новый метод поддержки формирования требований вакансии на основе семантического сопоставления сущностей знаний и навыков/компетенций предложенной структурно-семантической модели и методов кластеризации, который обеспечивает соответствие разрабатываемых требований в проектах вакансий реальным потребностям рынка труда.

4. По результатам экспериментальной оценки точность семантического поиска под требования пользователей составила ~0.82 по метрике MAP@5, что свидетельствует о достаточно высокой релевантности и адекватности выдаваемых системой рекомендаций по комплексной оценке экспертов, а также о том, что полученные рекомендации могут быть использоваться на практике для принятия решений в процессе формировании списка требований при составлении текстов вакансий.

5. На основе предложенных моделей, методов и алгоритмов разработан прототип интеллектуальной рекомендательной системы поддержки формирования требований в проектах вакансий. Проведена апробация прототипа в Югорский научно-исследовательский институт (г. Ханты-Мансийск), в компании ООО Фирма «Интерсвязь» (г. Челябинск) и в Челябинском государственном университете (г. Челябинск). По результатам экспертной оценки, отмечается высокая релевантность предлагаемых системой рекомендаций вариантов требований. Экспертами также отмечается существенное сокращение времени на подготовку и согласование списка требований, среднее время на подготовку одной вакансии снизилось с 4 до 1,5 часов или ↓62,5%; количество соискателей возросло с 3,7 на 4,3 или ↑16,2%; сокращение времени закрытия одной вакансии с 17,7 до 15,1 рабочих дней или ↓14,7%.

Перспективы дальнейших исследований. Дальнейшее развитие интеллектуальной системы включает в себя расширение возможностей использования нейросетевых моделей последнего поколения, т.н. LLM моделей, в задачах получения эмбеддингов текстов и в задаче извлечения сущностей знаний и навыков из текстов требований. А также возможности применения интеллектуальной рекомендательной системы экспертами для актуализации содержания профессиональных стандартов и других государственных классификаторов занятий.

СПИСОК ПУБЛИКАЦИЙ ПО ТЕМЕ ДИССЕРТАЦИИ

Статьи в изданиях, рекомендованных ВАК

1. Николаев И.Е. Сравнение нейросетевых моделей на архитектуре трансформеров в контексте задачи оценки компактности векторных представлений семантически близких текстов требований европейской классификации навыков ESCO / И.Е. Николаев, А.В. Мельников // Вестник Южно-Уральского государственного университета. Серия "Компьютерные технологии, управление, радиоэлектроника". – 2022. – Т. 22, №3. – С. 19-29.

2. Николаев И.Е. Интеллектуальный метод формирования списка требований профиля должности на основе нейросетевых моделей языка с использованием таксономии ESCO и корпуса онлайн-вакансий // Бизнес-информатика. – 2023. – Т. 17. № 2. – С. 71-84.

3. Николаев И.Е. Метод извлечения знаний и навыков/компетенций из текстов требований вакансий // Онтология проектирования. – 2023. – Т.13, №2(48). – С.282-293.

Статьи в изданиях, индексируемые в Scopus и Web of Science

4. Nikolaev, I. The Comparison of Distributive Semantics Models Applied to the Task of Short Job Requirements Clustering for the Russian Labor Market / I. Nikolaev, I. Ryazanov, D. Botov //8th Scientific Conference on Information Technologies for Intelligent Decision-Making Support (ITIDS 2020). – Atlantis Press, 2020. – С. 295-301.

5. Nikolaev I. Use of Topic Modelling for Improvement of Quality in the Task of Semantic Search of Educational Courses / I. Nikolaev, D. Botov, Y. Dmitrin, J. Klenin, A. Melnikov // 21st International Workshop on Computer Science and Information Technologies (CSIT 2019). – Atlantis Press, 2019. – С. 104-111.

6. Botov, D. Mining labor market requirements using distributional semantic models and deep learning / D. Botov, J. Klenin, A. Melnikov, Y. Dmitrin, I. Nikolaev, M. Vinel // Business Information Systems: 22nd International Conference, BIS 2019, Seville, Spain, June 26–28, 2019, Proceedings, Part II 22. – Springer International Publishing, – 2019. – С. 177-190.

7. Vinel, M. Experimental comparison of unsupervised approaches in the task of separating specializations within professions in job vacancies / M. Vinel, I. Ryazanov, D. Botov, I. Nikolaev // Artificial Intelligence and Natural Language: 8th Conference, AINL 2019, Tartu, Estonia, November 20–22, 2019, Proceedings 8. – Springer International Publishing, 2019. – С. 99-112.

8. Dmitrin, Y.V. Comparison of deep neural network architectures for authorship attribution of Russian social media texts / Y.V. Dmitrin, D.S. Botov, J.D. Klenin, I.E. Nikolaev // Computational Linguistics and Intellectual Technologies: Proceedings of the International Conference “Dialogue 2018”. – 2018.

Статьи в других изданиях

9. Ботов, Д.С., Извлечение информации с использованием нейросетевых моделей языка на примере анализа вакансий в системах онлайн-рекрутмента / Д.С. Ботов, Ю.Д. Кленин , И.Е. Николаев // Вестник Югорского государственного университета. – 2018. – №3 (50). – С. 37-48.

Свидетельства о регистрации программ для ЭВМ

10. Свидетельство о государственной регистрации программы для ЭВМ №2023669298 от 13 сентября 2023 г. «Автоматизированная система формирования рекомендаций для составления списка требований вакансии» / Николаев И.Е. М.: Роспатент, 2023.

Диссертант  И.Е. Николаев